Evaluació Preliminar del dataset 'Regensburg Pediatric Appendicitis'

Primera Entrega de la Pràctica

Aprenentatge Automàtic

Q1 Curs 2026/2027

Arnau Cullell Àlex Sanfeliu

UNIVERSITAT POLITÈCNICA DE CATALUNYA BARCELONATECH

Facultat d'Informàtica de Barcelona (FIB)

Barcelona, 26 d'octubre de 2026

Índex

1 Introducció del Conjunt de Dades **2**

1.1 Atributs a eliminar 5

2 Visualització de les dades i comparació amb variable objectiu **5**

2.1 Histogrames 5

2.2 Comparacions d'atributs amb Diagnosis 7

2.3 Matriu de Correlacions 10

3 Resultats Inicials amb Naïve Bayes **10**

4 Conclusió **12**

1 Introducció del Conjunt de Dades

El conjunt de dades 'Regensburg Pediatric Appendicitis' (disponible en **aquest enllaç**) va ser publicat el 6 de desembre del 2023, i la informació va ser agafada durant un període de 5 anys, des del 2016 fins al 2021. Recull informació sobre pacients pediàtrics ingressats amb sospites d'una possible apendicitis a l'hospital d'infants St. Hedwig en Regensburg, Alemanya.

Van aconseguir informació de 782 pacients, i cadascun està representat com una filera, i cada pacient té fins a 58 atributs assignats (alguns amb valor Nan). Aquests són molt variats, hi ha imatges, variables numèriques, categòriques i binàries. Com a variables objectius hi ha tres:

- **Diagnosis:** [appendicitis, no appendicitis]
- **Severity:** [complicated, uncomplicated]
- **Management:** [conservative, primary surgical, secondary surgical, simultaneous, etc...]

Les imatges no les utilitzarem, ja que creiem que amb els símptomes i amb atributs relacionats amb els ultrasons ja és suficient. També hem pensat de deixar com a única variable objectiu *Diagnosis*, i eliminar les altres dues per a que no influeixin al model. Com a conseqüència d'haver escollit aquesta variable, el model haurà de resoldre un problema de classificació binària, on haurà de dir si un pacient té apendicitis o no mirant els seus símptomes.

Aquestes són tots els atributs que hi ha al dataset:

Nom	**Tipus**	**Descripció**
`Age`	Contínua	Indica l'edat del pacient.
`BMI`	Contínua	Representa l'índex de massa corporal del pacient.
`Sex`	Categòrica	Diu si el pacient és dona o home.
`Height`	Contínua	Mostra l'alçada del pacient.
`Weight`	Entera	Mostra el pes del pacient.
`Length Of Stay`	Entera	Indica quant de temps ha estat el pacient a l'hospital.
`Management`	Categòrica	Diu com s'ha tractat l'apendicitis
`Severity`	Categòrica	Representa la severitat de l'apendicitis
`Diagnosis Presumptive`	Binària	Diu si hi ha sospita de que el pacient tingui apendicitis
`Diagnosis`	Binària	Diu si al final el pacient té apendicitis o no, **variable objectiu**
`Alvarado Score`	Integer	Puntuació entre 0 i 10, i es calcula segons els símptomes del pacient. Quant més gran és llavors hi ha més probabilitat d'apendicitis

Nom	Tipus	Descripció
`Paedriatic Appendicitis Score`	Integer	Puntuació entre 0 i 10. Funciona de forma molt similar a l'anterior, però té en compte altres paràmetres
`Appendix on US`	Binària	Ens diu si s'ha detectat l'apèndix al fer els ultrasons
`Appendix Diameter`	Integer	El màxim diàmetre de l'apèndix
`Migratory Pain`	Binària	Mostra si el pacient pateix de dolor abdominal
`Lower Right Abd Pain`	Binària	Ens diu si es va detectar dolor al palpitar la zona
`Contralateral Rebound Tenderness`	Binària	Mostra si hi ha dolor en la zona indicada
`Coughing Pain`	Binària	Indica si hi ha dolor abdominal al tosir
`Nausea`	Binària	Sensació de malestar / vòmits
`Loss of Appetite`	Binària	Representa si el pacient ha perdut l'apetit o no
`Body Temperature`	Contínua	Temperatura del pacient
`WBC Count`	Contínua	El nombre de leucòcits en una unitat de volum; paràmetre d'inflamació
`Neutrophil Percentatge`	Integer	WBC madur en granulocitat
`Segmented Neutrophils`	Integer	Granulocits neutrofílics madurs presents en sang; augmenta quan hi ha inflamació
`Neutrophilia`	Categòrica	Granulocits neutrofílics relatius; normalment resultat d'una infecció bacteriana
`RBC Count`	Contínua	El nombre de eritròcits en una unitat de volum de sang
`Hemoglobin`	Contínua	Nivell d'hemoglobina en sang
`RDW`	Contínua	Test de la sang, on es veu la diferència de volum i mida dels eritròcits
`Thrombocyte Count`	Integer	El nombre de plaquetes en una unitat de volum de sang
`Ketones in Urine`	Categòrica	Indica la presència de cosos de cetones en l'orina; en cas d'anorèxia
`RBC in Urine`	Categòrica	Indica la presència de sang en l'orina
`WBC in Urine`	Categòrica	Leucòcits en l'orina; en cas d'infecció
`CRP`	Integer	Proteïna produïda pel fetge, elevada en cas d'inflamació, infecció o ferida
`Dysuria`	Binària	Dolor o altres dificultats a l'orinar

Nom	Tipus	Descripció
Stool	Categòrica	Característiques de defecacions
Peritonitis	Categòrica	Espasmes dels músculs a la pared abdominal al fer palpitacions; normalment resultat d'una inflamació
Psoas Sign	Categòrica	Dolor abdominal produït per extensió de les caderes
Ipsilateral Rebound Tenderness	Categòrica	Estat en el qual el dolor del costat ipsilateral és sentit al deixar de pressionar la zona sobre l'abdomen
US Performed	Categòrica	Diu si s'han fet ultrasons o no
US Number	Categòrica	El número de l'ultrasó
Free Fluids	Categòrica	Fluids lliures dins de l'abdomen
Appendix Wall Layers	Categòrica	Distribució i característiques de les capes de l'apèndix
Target Sign	Categòrica	Imatge axial de l'apèndix
Appendicolith	Categòrica	Indica la presència d'un apendicolit (fecaloma calcificat) a l'apèndix
Perfusion	Categòrica	Descriu el flux sanguini a la paret de l'apèndix
Perforation	Categòrica	Indica si hi ha signes ecogràfics de perforació de l'apèndix
Surrounding Tissue Reaction	Categòrica	Mostra si hi ha signes d'inflamació als teixits que envolten l'apèndix
Appendicular Abscess	Categòrica	Indica si hi ha una massa o un abscés relacionat amb l'apèndix
Abscess Location	Categòrica	Indica la localització intraperitoneal de l'abscés
Pathological Lymph Nodes	Binària	Indica si hi ha ganglis limfàtics intraabdominals augmentats i inflamats
Lymph Nodes Location	Categòrica	Indica la localització abdominal dels ganglis limfàtics patològics
Bowel Wall Thickening	Binària	Indica si la paret intestinal està engruixida per edema
Conglomerate of Bowel Loops	Binària	Indica si hi ha un agrupament d'anses intestinals associat a inflamació intraperitoneal
Ileus	Categòrica	Indica si hi ha signes ecogràfics d'ili paralític, com anses dilatades o absència de peristaltisme
Coprostasis	Categòrica	Indica si hi ha acumulació o retenció de femta al còlon

Nom	Tipus	Descripció
`Meteorism`	Categòrica	Indica si hi ha una acumulació excessiva de gas a l'intestí
`Enteritis`	Categòrica	Indica si hi ha signes ecogràfics d'inflamació intestinal (enteritis)
`Gynecological Findings`	Categòrica	Recull troballes ginecològiques anormals, com ara quists o torsió ovàrica

Taula 1: Descripció dels atributs

1.1 Atributs a eliminar

En aquest apartat mostrem les variables que cal eliminar i el perquè de la nostra decisió:

- **Severity:** és la segona variable objectiu del dataset, i aquesta dona informació sobre la severitat de la pròpia apendicitis, per tant, ja diu si el pacient té apendicitis o no i això provocaria que el model estigués esbiaixat.
- **Management:** la tercera variable objectiu, i diu com s'ha tractat l'apendicitis, i per tant, igual que a l'anterior atribut, el model estaria esbiaixat.
- **Diagnosis Presumptive:** aquest atribut indica si un doctor sospitava de que el pacient tingués apendicitis mirant els símptomes. Com el model vol simular això mateix hem decidit eliminar-la per a que el problema no sigui tan fàcil.
- **Length Of Stay:** aquesta variable indica quants dies ha estat el pacient a l'hospital ingressat. Aquesta és una variable temporal, i com no es pot obtindre a l'ingressar un nou pacient cal eliminar-la.
- **Alvarado Score:** és una puntuació del 0 al 10 que diu com de probable és que el pacient pateixi d'apendicitis segons els símptomes que té. Això ho voldrem simular amb el model, i per tant, també l'eliminarem.
- **Pedriatic Appendicitis Score:** és un altre tipus de puntuació, i l'eliminem pel mateix motiu d'abans.
- **US Number:** és només un identificador de la imatge d'ultrasons, per tant només afegeix soroll i cap informació útil.

2 Visualització de les dades i comparació amb variable objectiu

Després d'haver agafat tot el dataset i d'haver eliminat els atributs que no calien llavors vam fer una visualització bàsica de les dades. En aquesta vam poder extreure molta informació útil que ens va servir per després.

2.1 Histogrames

Els hem separat en dos tipus, segons si es fan sobre variables numèriques o categòriques. Cal remarcar que sobre 'Age' i sobre 'BMI' vam eliminar dos outliers (assignant valors Nan) que no

permetien veure bé els histogrames pertinents.

En el següents histogrames podem observar com es comporten les principals variables numèriques. Totes semblen que segueixen una distribució normal, `Appendix_Diameter` podria ser l'única que no la segueix tant.

Visualment podem deduir que la majoria dels pacients tenen uns 11 o 12 anys, una alçada de 1.40m i un pes de 30/40Kg. Pel que fa a `Appendix_Diameter` hem de tindre en compte que el diàmetre d'un apèndix sa d'un infant és de com a molt sis mm, i en l'histograma podem observar com hi ha un pic entre els sis i els vuit mm, per tant, una separació d'infants sans i els altres que probablement tinguin apendicitis.

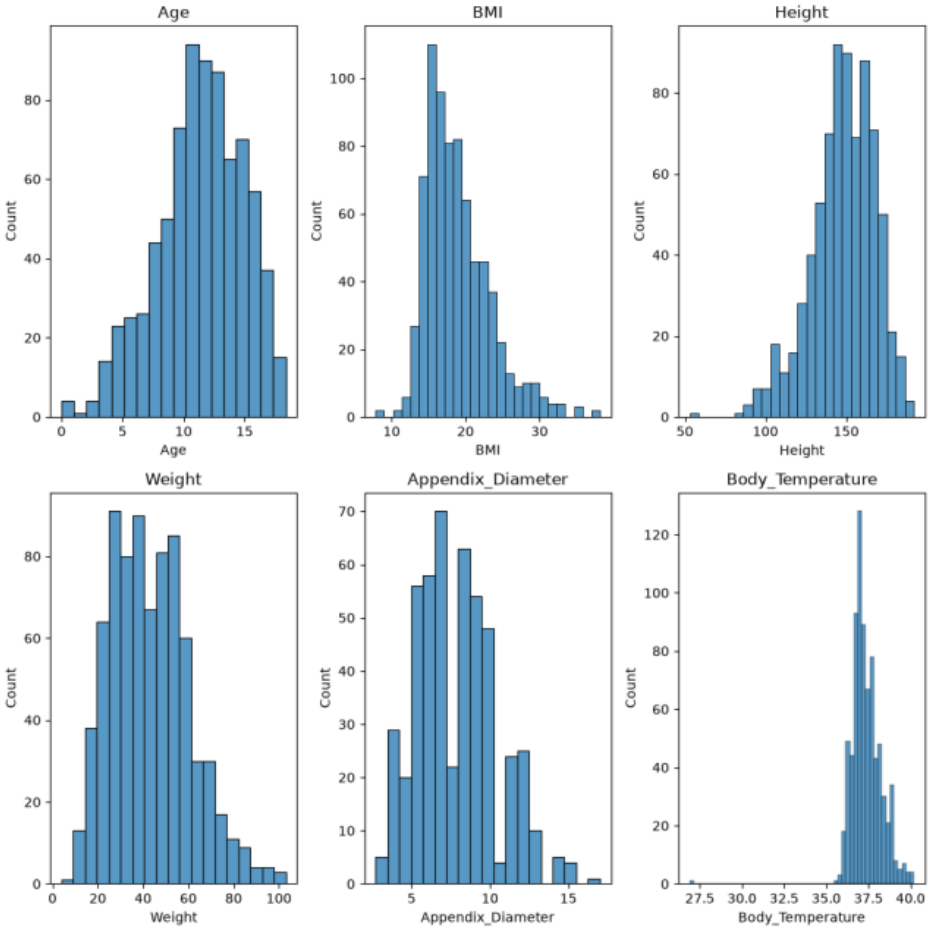


Figura 1: Histogrames de les variables numèriques.

Amb els histogrames d'atributs categòrics podem veure com hi ha uns 470 pacients amb apendicitis i uns 310 sense, això correspon a un 60% de pacients amb la malaltia i l'altre 40% no la tenen. La relació entre dones i homes és molt semblant, quasi del 50% cadascun. La gran majoria de pacients se'ls va veure l'apèndix en l'ultrasò, encara que no vol dir que estiguin lliures d'apendicitis, tal i com es veu al notebook. Pel que fa a la resta d'atributs, la majoria de pacients tenien nàusees, no els hi dolia al tossir i tampoc tenien peritonitis (efecte de l'apendicitis, on l'apèndix reventa i pot infectar altres òrgans).

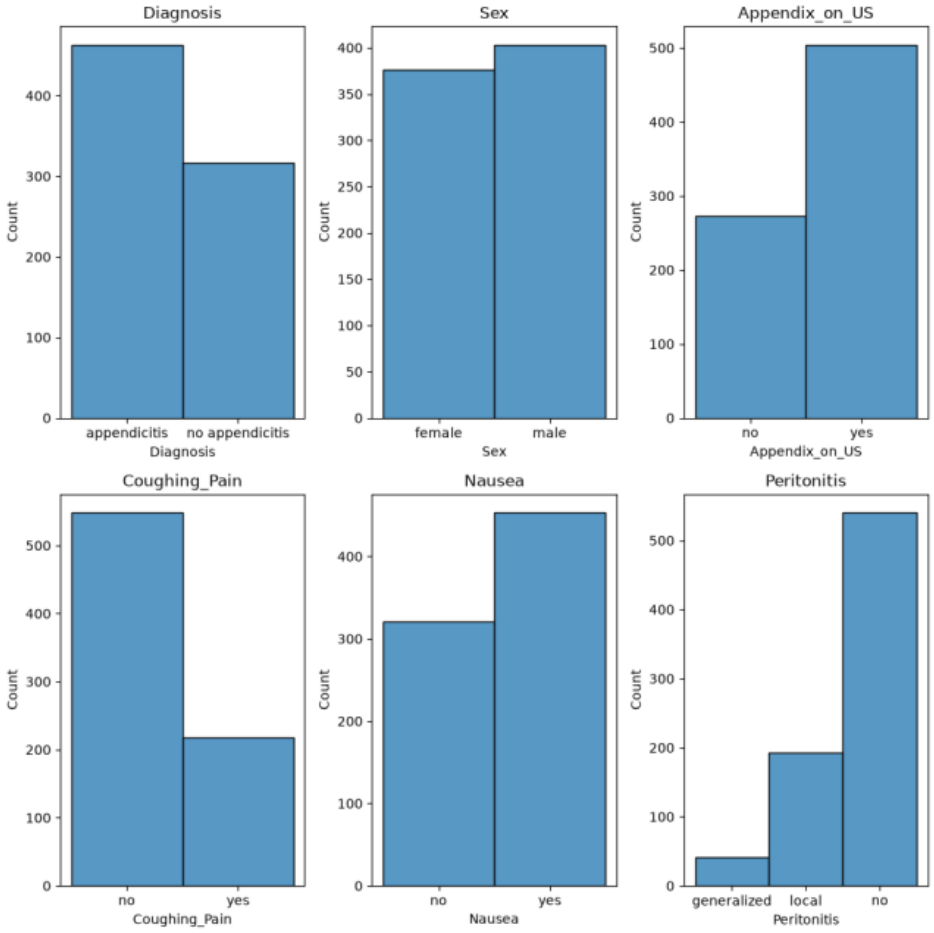


Figura 2: Histogrames de les variables categòriques.

2.2 Comparacions d'atributs amb Diagnosis

El gràfic de sota ens mostra com la peritonitis no ens aporta gaire sobre si el pacient té apendicitis, ja que es pot veure com si no té peritonitis es igual de probable que tingui apendicitis. Segurament l'efecte seria a l'inrevés, si el pacient té peritonitis llavors té o ha tingut apendicitis.

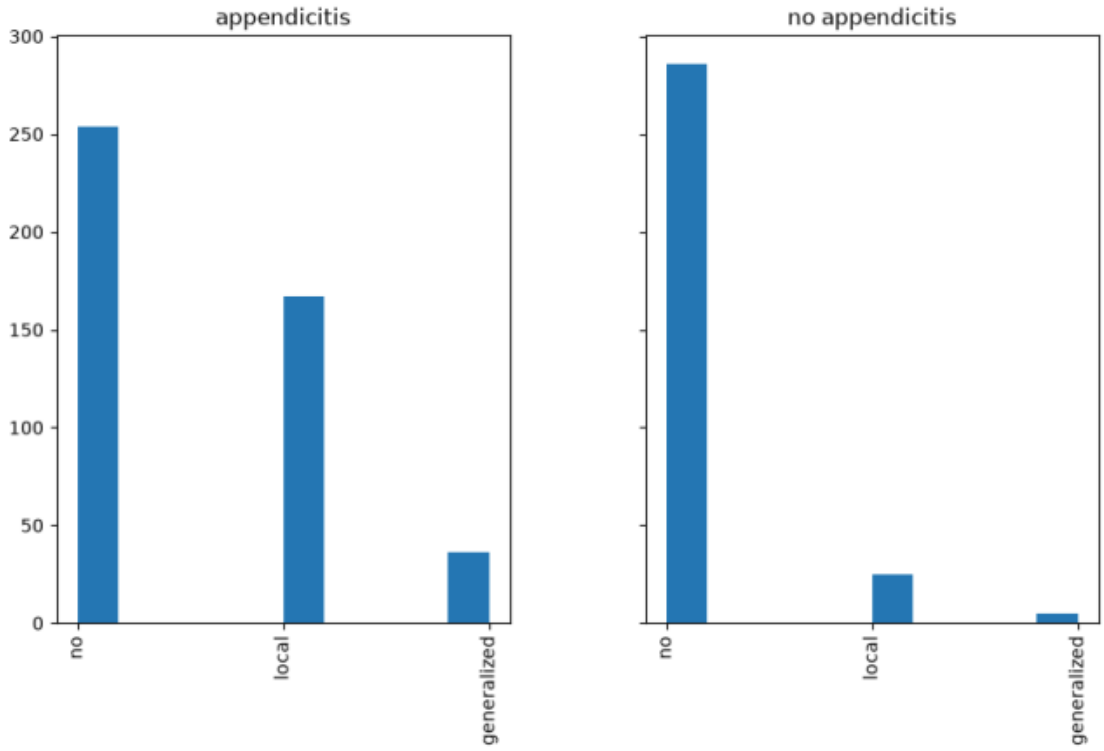


Figura 3: Relació entre el diagnòstic i la peritonitis.

El segon gràfic ens dius que la majoria de pacients amb apendicitis tenen uns 12 anys, però els que no en tenen també solen tindre aquesta edat, per tant no aporta molta informació.

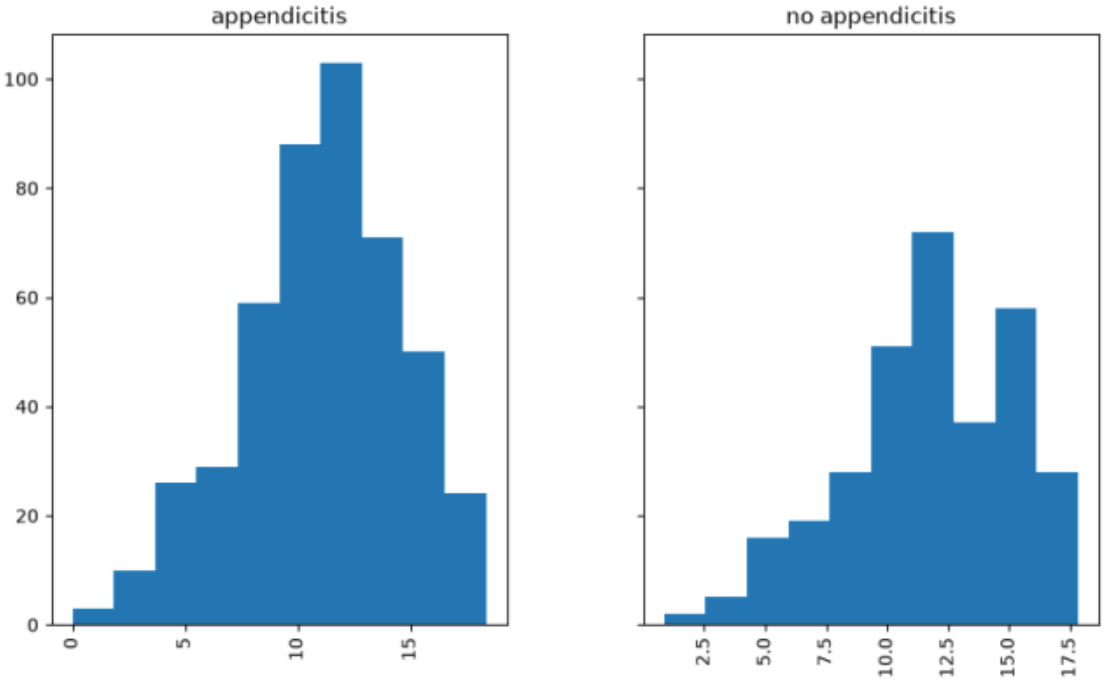


Figura 4: Distribució de l'edat segons el diagnòstic.

El tercer és molt interessant, es pot veure clarament com si el pacient pateix de dolor abdominal

a sota a la dreta hi ha bastantes probabilitats de que tingui apendicitis. No ho confirma, però serà un bon indicador pel model.

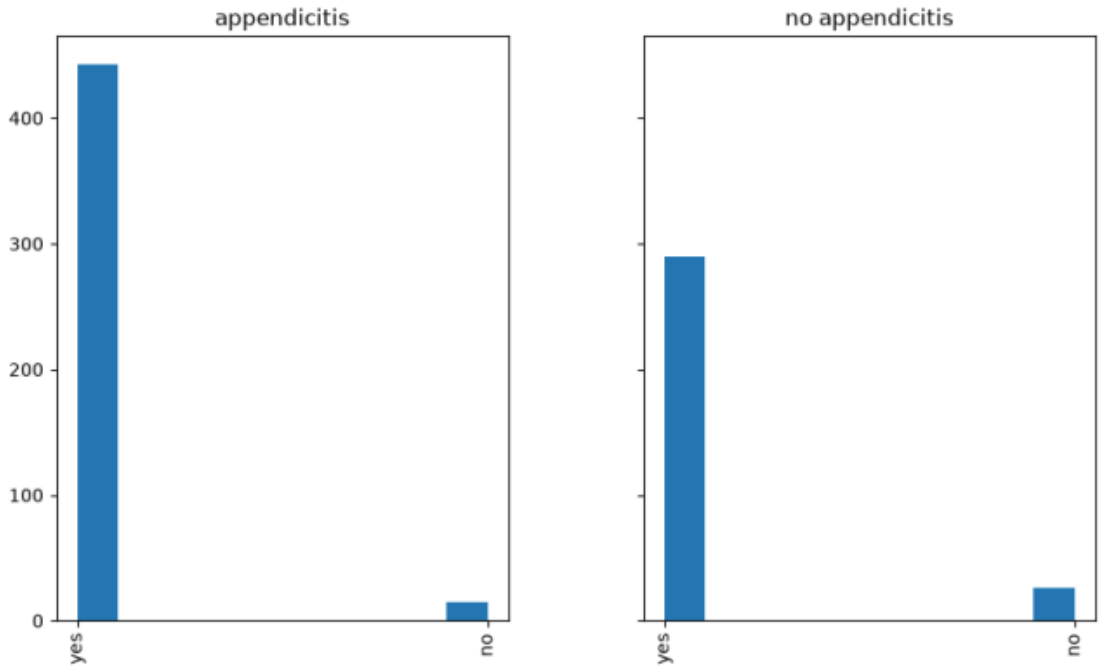


Figura 5: Relació entre el diagnòstic i el dolor a la part inferior dreta de l'abdomen.

L'últim gràfic ens mostra l'hipòtesi vista abans, es pot veure clarament com els pacients amb apendicitis solen tindre un diàmetre més gran a 6, mentre que els que no és menor a 6. Per tant, també serà una bona variable pel model.

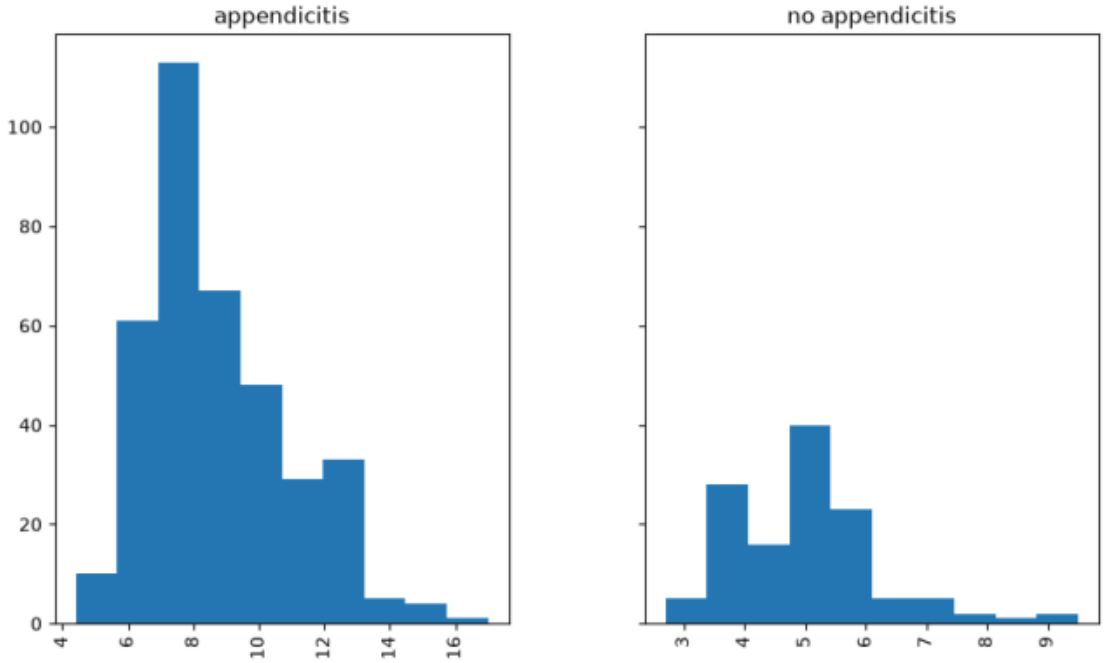


Figura 6: Distribució del diàmetre de l'apèndix segons el diagnòstic.

2.3 Matriu de Correlacions

Hem afegit Diagnosis a la matriu, transformamnt el valor a 1 si en té la malaltia, d'aquesta forma podem mirar per sobre com afecta cada variable numèrica a Diagnosis. Es pot detectar fàcilment com el que més sembla estar correlacionat amb Diagnosis és el diàmetre de l'apèndix, seguit del 'Segmented Neutrophils' i 'WBC Count'. Es pot veure com el BMI està molt relacionat amb l'altura i el pes, quelcom obvi. L'edat sembla estar correlacionada negativament amb bastantes variables, però amb Diagnosis no té gaire importància.

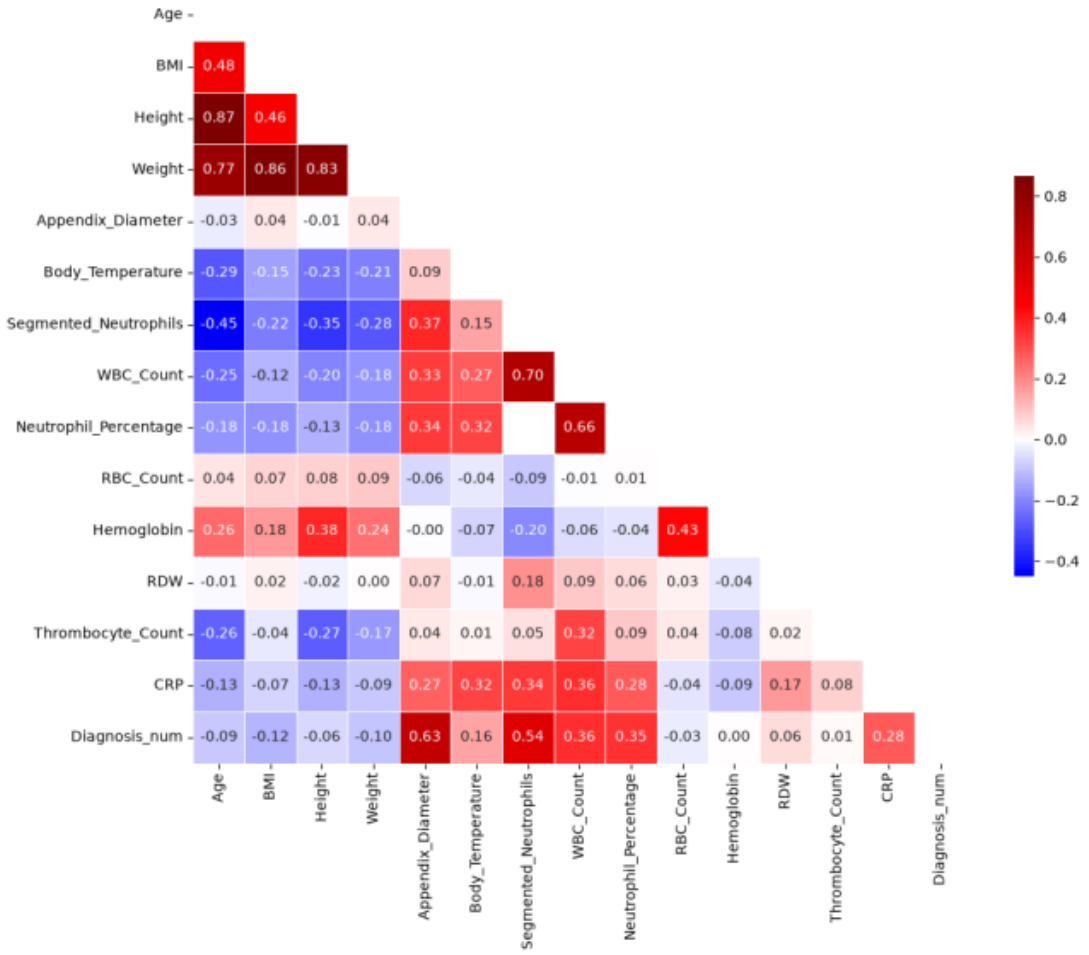


Figura 7: Matriu de correlacions entre les variables numèriques.

3 Resultats Inicials amb Naïve Bayes

Tot el procés fins arribar al model es pot veure detalladament al notebook. Resumidament: hem fet un split de 70% train i 30% test; després hem preprocessat les dades, aplicant eliminació de columnes amb casi tot Nan, la imputació de valors Nan amb valors del train com la mediana o la moda, i finalment un One-hot encoding per les variables categòriques (no hem aplicat escalat perquè es demanava preprocessat bàsic); amb les dades netes hem fet validació creuada i hem entrenat el model de Bayes, ens ha donat un acert del 68%; després hem escollit el millor model provant amb diferents valors de `var_smoothing` (per evitar divisions entre zero al dividir per la variància de variables categòriques), i hem obtingut un acert del 72%; finalment hem fet una

predicció amb les dades del test i aquest últim model, i hem obtingut un acert del 74%, per tant, sense error d'overfitting.

Les imatges de sota mostren el 74% d'encert del que estàvem parlant. També ens mostra com el model quan afirma que un pacient té apendicitis ho diu amb una seguretat del 92% (precision), però, només identifica al 60% de pacients amb apendicitis (recall), un percentatge prou baix. Per una altra banda, identifica bé al 93% de pacients sense apendicitis, però en dona molts falsos positius, ja que quan afirma que algú no té apendicitis ho diu amb només una seguretat del 62%.

Resultats sobre el conjunt de Test

	precision	recall	f1-score	support
appendicitis	0.92	0.60	0.72	136
no appendicitis	0.62	0.93	0.75	98
accuracy			0.74	234
macro avg	0.77	0.76	0.73	234
weighted avg	0.80	0.74	0.73	234

Figura 8: Resultats del model Naïve Bayes sobre el conjunt de test.

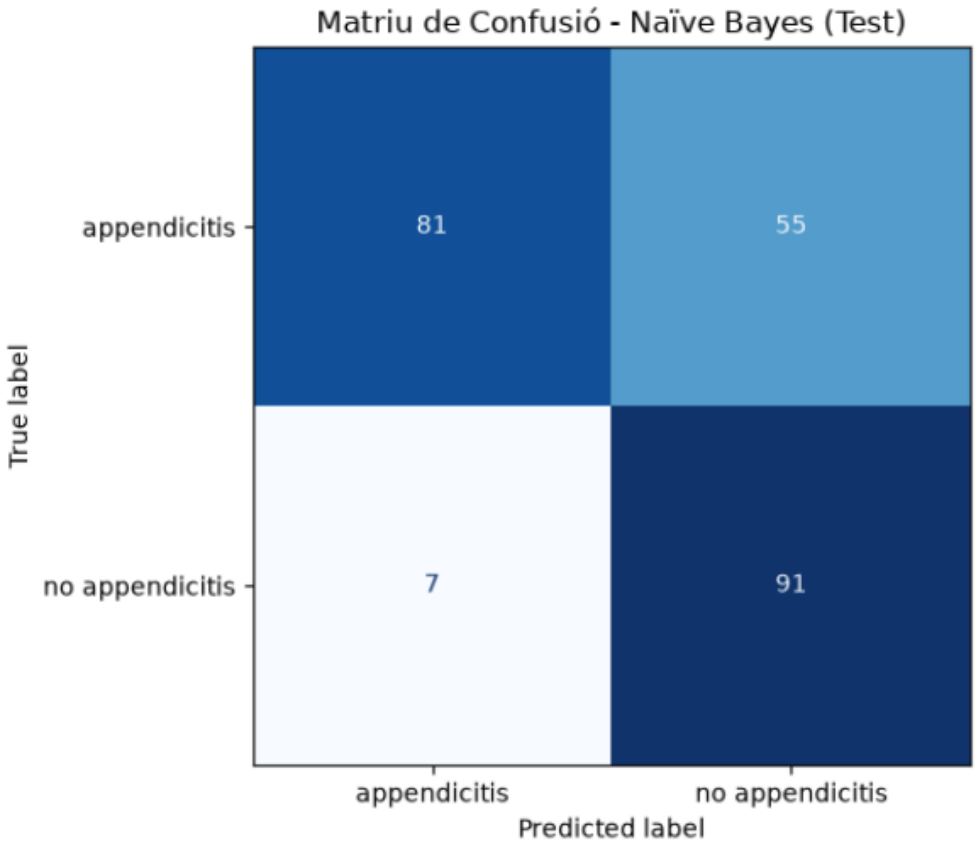


Figura 9: Matriu de confusió del model Naïve Bayes sobre el conjunt de test.

4 Conclusió

Personalment creiem que aquest és un bon conjunt de dades per a desenvolupar la pràctica. El primer motiu es basa en que és un dataset que necessita d'un preprocessat molt concret i s'ha d'estudiar millor. El segon motiu es basa en que creiem que podem millorar bastant el model classificador, i arribar a un percentatge més alt si tractem bé les dades i estudiem altres models disponibles.